МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО»
МЕГАФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ ТЕХНОЛОГИЙ И УПРАВЛЕНИЯ
ФАКУЛЬТЕТ ПРОГРАММНОЙ ИНЖЕНЕРИИ И КОМПЬЮТЕРНОЙ ТЕХНИКИ

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ № 3

Студент: Садовщикова София Ивановна

Группа: P3268

Преподаватель: Климов Игорь Викторович

Санкт-Петербург 2026

Оглавление

Задание 1. Подготовка материалов для работы

Задание 2. Сравнительный анализ алгоритмов

- 2.1. Каталог 450389TXT
- 2.2. Каталог 450389DOC
- 2.3. Каталог 450389PIC
- 2.4. Каталог 450389VID
- 2.5. Каталог 450389PRG
- 2.6. Каталог 450389SMALL

Задание 3. Влияние размера словаря

Задание 4. Максимальное сжатие из командной строки

Задание 5. Solid- и SFX-архивы

Задание 6. Ручное сжатие RLE и Хаффмана

- 6.1. Кодирование RLE
- 6.2. Кодирование Хаффмана

Выводы

Архивы для проверки

Задание 1. Подготовка материалов для работы

Для исследования сжатия в 7-Zip подготовлены шесть наборов файлов. В названиях каталогов используется номер ИСУ 450389. Для каждого набора далее сравниваются методы LZMA2, Deflate, BZip2 и PPMd.

Каталог	Содержимое	Исходный размер, байт	Минимум по заданию, МБ
450389TXT	Текстовые файлы .txt	10 485 760	10
450389DOC	Документы .docx, .odt и др.	15 510 874	10
450389PIC	Фотографии .jpg	24 649 578	20
450389VID	Видеофайлы .mp4	21 529 482	20
450389PRG	Исполняемые файлы .exe, .com	16 959 128	10
450389SMALL	Набор небольших файлов	14 082 482	10

Размер TXT принят равным 10 485 760 байт: пять файлов по 2×1024^2 байт, созданных командой из подготовки к работе. Его фактический размер необходимо сверить со свойствами каталога. Остальные исходные размеры указаны по предоставленным данным.

Для SMALL файлы подбираются и копируются с помощью FAR. При подсчёте используется суммарный размер содержимого файлов, а не занятое на диске место. Все указанные наборы достигают минимального объёма, установленного заданием.

Подтверждающие скриншоты: слева в FAR — список файлов в режиме «Краткий», справа — «Быстрый просмотр» со статистикой каталога. Ниже оставлены места для шести снимков; сами изображения для этой лабораторной пока не предоставлены.

450389TXT

[Место для скриншота свойств каталога 450389TXT]

Скриншот 1 — Файлы, размер и количество файлов каталога 450389TXT

450389DOC

[Место для скриншота свойств каталога 450389DOC]

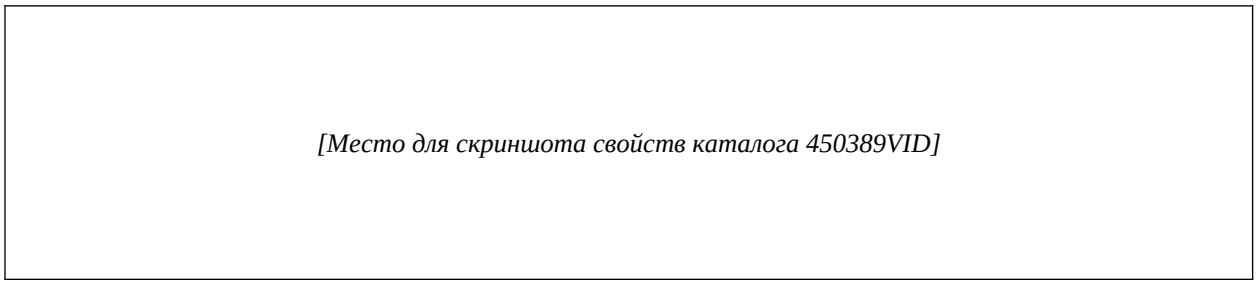
Скриншот 2 — Файлы, размер и количество файлов каталога 450389DOC

450389PIC

[Место для скриншота свойств каталога 450389PIC]

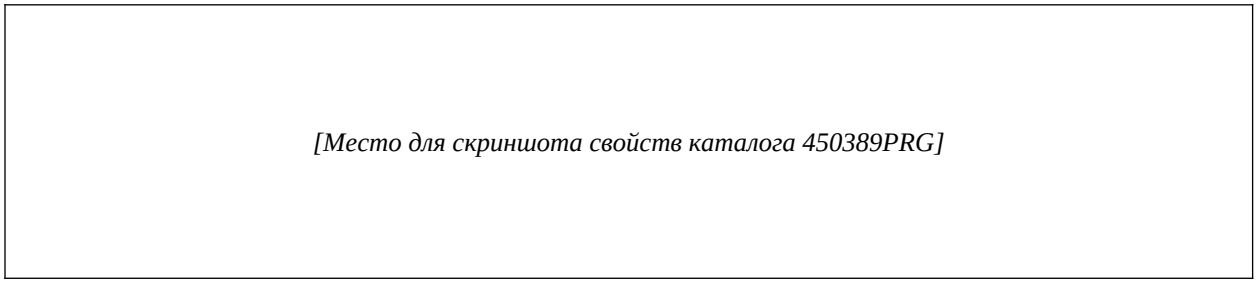
Скриншот 3 — Файлы, размер и количество файлов каталога 450389PIC

450389VID



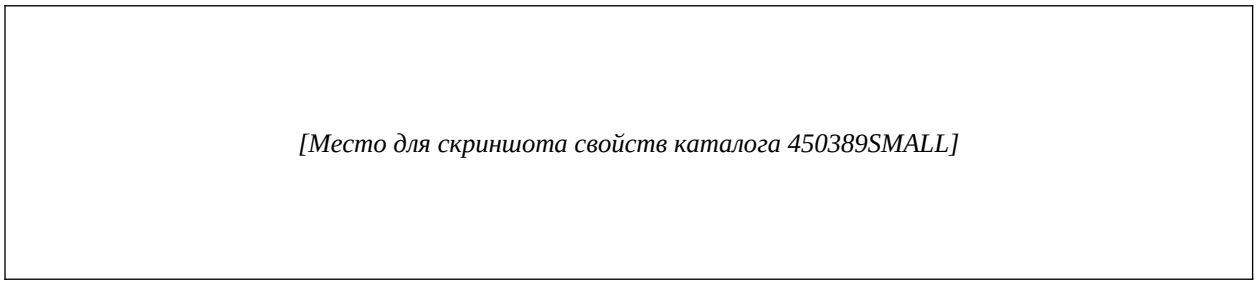
Скриншот 4 — Файлы, размер и количество файлов каталога 450389VID

450389PRG



Скриншот 5 — Файлы, размер и количество файлов каталога 450389PRG

450389SMALL



Скриншот 6 — Файлы, размер и количество файлов каталога 450389SMALL

Задание 2. Сравнительный анализ алгоритмов

Каждый каталог упакован отдельно четырьмя методами при уровне сжатия «5 — Нормальный». Для LZMA2, BZip2 и PPMd используется формат 7z, для Deflate — ZIP. В таблицах приведены результаты, сообщённые при выполнении работы; повторные запуски и независимое измерение времени не проводились.

В столбце памяти приведена оценка «Объём памяти для упаковки» из настроек 7-Zip, а не измеренный пик потребления оперативной памяти. Значения сохранены по предоставленным данным: LZMA2 — 4928 МБ, Deflate — 1088 МБ, BZip2 — 160 МБ, PPMd — 18 МБ.

Размер архива в КБ = размер архива в байтах / 1024. Коэффициент сжатия = размер архива / суммарный исходный размер файлов × 100 %. Чем меньше коэффициент, тем меньше итоговый архив. Значение выше 100 % означает увеличение размера.

Время «< 1 с» означает, что сжатие было описано как моментальное и точное время не измерено. Остальные значения времени перенесены из наблюдений. Сравнение очень коротких запусков носит ориентировочный характер.

2.1. Каталог 450389TXT

Алгоритм	Время сжатия, с	Память для упаковки, МБ	Размер архива, КБ	Коэффициент, %
LZMA2	< 1	4928	1,94	0,0189
Deflate (ZIP)	0,1	1088	33,52	0,3273
BZip2	1	160	2,11	0,0206
PPMd	1	18	1,94	0,0189

Минимальный размер одинаков у LZMA2 и PPMd: 1984 байта. Повторяющийся текст хорошо сжимается обоими методами. При одинаковом размере PPMd имеет меньшую указанную оценку памяти — 18 МБ против 4928 МБ у LZMA2.

2.2. Каталог 450389DOC

Алгоритм	Время сжатия, с	Память для упаковки, МБ	Размер архива, КБ	Коэффициент, %
LZMA2	1,5	4928	8 559,58	56,51
Deflate (ZIP)	0,1	1088	15 147,38	100,00
BZip2	< 1	160	15 138,99	99,94
PPMd	4	18	15 208,16	100,40

Наименьший архив получен методом LZMA2 — 8 765 007 байт (56,51 %). Остальные методы почти не сократили набор. Документы .docx и .odt уже содержат сжатые данные; при этом LZMA2 в сплошном архиве может использовать повторения между похожими файлами. Точная причина различий требует анализа состава документов. Архив Deflate на 45 байт больше исходного набора; при округлении коэффициент отображается как 100,00 %.

2.3. Каталог 450389PIC

Алгоритм	Время сжатия, с	Память для упаковки, МБ	Размер архива, КБ	Коэффициент, %
LZMA2	2,5	4928	22 673,20	94,19
Deflate (ZIP)	0,1	1088	23 121,15	96,05
BZip2	0,5	160	22 439,03	93,22
PPMd	6	18	22 145,38	92,00

По размеру лучшим оказался PPMd: 22 676 873 байта (92,00 %). При этом он потребовал 6 с, а Deflate — 0,1 с по предоставленным наблюдениям. Фотографии JPEG уже сжаты, поэтому дополнительное уменьшение размера ограничено. Преимущество PPMd относится к данному набору изображений.

2.4. Каталог 450389VID

Алгоритм	Время сжатия, с	Память для упаковки, МБ	Размер архива, КБ	Коэффициент, %
LZMA2	1	4928	20 963,51	99,71
Deflate (ZIP)	0,1	1088	20 980,53	99,79
BZip2	0,1	160	21 062,94	100,18
PPMd	6	18	21 430,58	101,93

Наименьший архив получен методом LZMA2: 21 466 631 байт (99,71 %). Выигрыш составил всего 62 851 байт. Видео MP4 обычно уже сжато, поэтому повторная архивация малоэффективна; BZip2 и PPMd в этом опыте увеличили общий размер.

2.5. Каталог 450389PRG

Алгоритм	Время сжатия, с	Память для упаковки, МБ	Размер архива, КБ	Коэффициент, %
LZMA2	2	4928	4 649,93	28,08
Deflate (ZIP)	0,1	1088	6 421,20	38,77
BZip2	< 1	160	5 826,11	35,18
PPMd	1	18	5 332,56	32,20

Лучший результат по размеру показал LZMA2: 4 761 531 байт (28,08 %). Метод эффективно использует повторяющиеся последовательности в исполняемых файлах. PPMd оказался быстрее по указанным наблюдениям, но сформировал больший архив.

2.6. Каталог 450389SMALL

Алгоритм	Время сжатия, с	Память для упаковки, МБ	Размер архива, КБ	Коэффициент, %
LZMA2	33	4928	1 473,30	10,71
Deflate (ZIP)	0,1	1088	10 886,48	79,16
BZip2	1	160	2 829,24	20,57
PPMd	2	18	2 048,44	14,90

Самый маленький архив получен методом LZMA2: 1 508 663 байта (10,71 %), однако время составило 33 с. PPMd дал 2 097 601 байт (14,90 %) за 2 с. Сплошное сжатие 7z может использовать общие фрагменты разных небольших файлов; ZIP сжимает файлы отдельно и дополнительно хранит служебные записи для каждого файла. Это может объяснять большой размер ZIP для набора из множества файлов.

Задание 3. Влияние размера словаря

Для каталога 450389TXT выбран метод LZMA2, уровень сжатия «5 — Нормальный». Исследованы словари 64 КБ, 16 МБ, 128 МБ и максимальный доступный размер 3840 МБ. По сообщению исполнителя вручную изменялся только словарь. В окне максимального словаря 7-Zip отображает два потока; вручную число потоков не менялось. Поэтому фиксируется фактически показанная оценка памяти программы.

Словарь	Память для сжатия, МБ	Память для распаковки, МБ	Архив, байт	Коэффициент, %
64 КБ	88	3	2959	0,028219
16 МБ	2496	18	1980	0,018883
128 МБ	13888	130	1980	0,018883
3840 МБ (max)	38920	3842	—	—

Память в таблице — оценка 7-Zip, а не измеренный расход. При словаре 3840 МБ программа заблокировала операцию: требовалось 38 920 МБ, установленная RAM — 32 690 МБ, установленный лимит — 26 152 МБ. Архив для максимального словаря не создан; прочерки не означают нулевой размер.

Увеличение словаря с 64 КБ до 16 МБ сократило архив с 2959 до 1980 байт. Дальнейшее увеличение до 128 МБ не изменило размер, но повысило оценку памяти сжатия с 2496 до 13 888 МБ и распаковки с 18 до 130 МБ. Большой словарь бесполезен, если меньший уже охватывает полезные повторения исходных данных. Для данного набора из успешно испытанных вариантов рациональнее словарь 16 МБ.

[Место для скриншота: Архивы 450389TXT64, 450389TXT16 и 450389TXT128 в FAR, режим «Детальный»]

Скриншот 7 — Архивы 450389TXT64, 450389TXT16 и 450389TXT128 в FAR, режим «Детальный»

[Место для скриншота: Отказ 7-Zip при словаре 3840 МБ: недостаточно памяти]

Скриншот 8 — Отказ 7-Zip при словаре 3840 МБ: недостаточно памяти

Задание 4. Максимальное сжатие из командной строки

Каталоги 450389PIC и 450389VID упакованы по отдельности консольной версией 7-Zip с максимальным уровнем сжатия. Команды выполняются из родительского каталога, чтобы готовые архивы находились вне исходных папок. Параметр -mx=9 задаёт максимальный уровень, -m0=LZMA2 выбирает алгоритм.

```
"C:\Program Files\7-Zip\7z.exe" a -t7z -m0=LZMA2 -mx=9 "450389PIC_max.7z" ".\450389PIC\"
"C:\Program Files\7-Zip\7z.exe" a -t7z -m0=LZMA2 -mx=9 "450389VID_max.7z" ".\450389VID\"
```

Каталог	Оригинал, байт	Архив, байт	Архив / оригинал, %	Уменьшение, %
450389PIC	24 649 578	23 217 366	94,19	5,81
450389VID	21 529 482	21 466 448	99,71	0,29

По сравнению с нормальным уровнем LZMA2 из задания 2 архив PIC стал на 6 байт больше, а VID — на 183 байта меньше. Для этих наборов максимальный уровень почти не улучшил результат. JPEG и MP4 уже используют сжатие; повторная упаковка даёт небольшой выигрыш.

[Место для скриншота: Команда и результат максимального сжатия 450389PIC в CMD]

Скриншот 9 — Команда и результат максимального сжатия 450389PIC в CMD

[Место для скриншота: Команда и результат максимального сжатия 450389VID в CMD]

Скриншот 10 — Команда и результат максимального сжатия 450389VID в CMD

[Место для скриншота: Архивы 450389PIC_max.7z и 450389VID_max.7z в FAR, режим «Детальный»]

Скриншот 11 — Архивы 450389PIC_max.7z и 450389VID_max.7z в FAR, режим «Детальный»

Задание 5. Solid- и SFX-архивы

Для каталога 450389SMALL созданы три архива с LZMA2 на нормальном уровне: непрерывный Solid, обычный без Solid и самораспаковывающийся SFX без Solid. Для сопоставимости SFX и обычного архива в обоих случаях непрерывное сжатие отключено. Использованы следующие команды из родительского каталога.

```
"C:\Program Files\7-Zip\7z.exe" a -t7z -m0=LZMA2 -mx=5 -ms=on "450389SMALL_solid.7z" ". \450389SMALL\"
```

```
"C:\Program Files\7-Zip\7z.exe" a -t7z -m0=LZMA2 -mx=5 -ms=off "450389SMALL обычный.7z" ". \450389SMALL\"
```

```
"C:\Program Files\7-Zip\7z.exe" a -t7z -m0=LZMA2 -mx=5 -ms=off -sfx "450389SMALL_sfx.exe" ". \450389SMALL\"
```

Тип архива	Размер, байт	Размер, КБ	Архив / оригинал, %
Обычный, без Solid	8 600 582	8 399,01	61,07
SFX, без Solid	8 795 142	8 589,01	62,45
Solid	1 508 589	1 473,23	10,71

Solid-архив — самый маленький: 1 508 589 байт. При непрерывном сжатии общие фрагменты разных файлов могут использоваться совместно. Обычный архив сжимает файлы независимо, поэтому для этого набора его размер значительно больше.

SFX больше обычного архива на 194 560 байт, или 190 КБ. Разница соответствует добавленному модулю самораспаковки. Преимущество SFX — извлечение файлов без установленного архиватора. Недостатки — дополнительный размер и зависимость исполняемого модуля от платформы: созданный .exe предназначен для Windows.

Преимущество Solid — лучшее сжатие набора похожих файлов. Главный недостаток — для извлечения отдельного файла может потребоваться обработать предшествующие данные внутри блока; изменение содержимого также может потребовать повторного сжатия блока. Обычный архив удобнее для независимого доступа к отдельным файлам.

[Место для скриншота: Создание Solid-архива: команда и результат в CMD]

Скриншот 12 — Создание Solid-архива: команда и результат в CMD

[Место для скриншота: Создание обычного архива: команда и результат в CMD]

Скриншот 13 — Создание обычного архива: команда и результат в CMD

[Место для скриншота: Создание SFX-архива: команда и результат в CMD]

Скриншот 14 — Создание SFX-архива: команда и результат в CMD

[Место для скриншота: Все три архива SMALL в FAR, режим «Детальный»]

Скриншот 15 — Все три архива SMALL в FAR, режим «Детальный»

Задание 6. Ручное сжатие RLE и Хаффмана

Исходная строка: «Садовщикова София Ивановна». В ней 26 символов, включая два пробела. Регистр учитывается: И и и, С и с являются разными символами. Для учебного расчёта принят однобайтовый исходный текст в Windows-1251 без служебных заголовков: 26 × 8 = 208 бит, или 26 байт.

6.1. Кодирование RLE

RLE заменяет последовательность одинаковых подряд символов парой «символ — число повторений». В данном ФИО соседних одинаковых символов нет, поэтому получаются 26 серий длины 1. Обозначение ␣ ниже соответствует одному обычному пробелу, а не дополнительному символу исходной строки.

```
С1а1д1о1в1щ1и1к1о1в1а1␣1С1о1ф1и1я1␣1И1в1а1н1о1в1н1а1
```

В выбранном представлении символ и счётчик занимают по одному байту. Объём результата: 26 × (1 + 1) = 52 байта, или 416 бит. Коэффициент: 52 / 26 × 100 % = 200 %. Вместо сжатия произошло увеличение объёма вдвое. Это вывод для указанного формата RLE; другие реализации могут отдельно обрабатывать одиночные символы.

6.2. Кодирование Хаффмана

Сначала подсчитаны частоты всех символов. Для построения дерева на каждом шаге объединяются два узла с наименьшими частотами. При равных частотах возможны разные, одинаково эффективные деревья. Ниже приведён один допустимый порядок объединений:

```
А = И(1) + д(1) = 2
Б = к(1) + ф(1) = 2
В = щ(1) + я(1) = 2
Г = пробел(2) + С(2) = 4
Д = и(2) + н(2) = 4
Е = А(2) + Б(2) = 4
Ж = В(2) + а(4) = 6
З = в(4) + о(4) = 8
К = Г(4) + Д(4) = 8
Л = Е(4) + Ж(6) = 10
М = З(8) + К(8) = 16
Корень = Л(10) + М(16) = 26
```

Левой ветви назначен 0, правой — 1. Путь от корня до символа задаёт его код. Более частые символы а, в и о получили трёхбитовые коды, остальные — четырёхбитовые.

Символ	Частота	Код	Длина кода, бит	Всего бит
Пробел	2	1100	4	8
И	1	0000	4	4
С	2	1101	4	8
а	4	011	3	12
в	4	100	3	12
д	1	0001	4	4
и	2	1110	4	8
к	1	0010	4	4
н	2	1111	4	8
о	4	101	3	12
ф	1	0011	4	4
щ	1	0100	4	4
я	1	0101	4	4
Итого	26	—	—	92

Подстановка кодов в исходную строку даёт следующую последовательность. Пробелы между кодами и переводы строк добавлены для наглядности и в размер битовой последовательности не входят; 1100 кодирует настоящий пробел между частями ФИО.

```
1101 011 0001 101 100 0100 1110 0010 101 100 011
1100
1101 101 0011 1110 0101
1100
0000 100 011 1111 101 100 1111 011
```

Объём полезных данных: 3 × 4 × 3 + 4 × 2 × 4 + 6 × 1 × 4 = 36 + 32 + 24 = 92 бита. Коэффициент: 92 / 208 × 100 % = 44,23 %. Уменьшение объёма полезных данных: 55,77 %. При сохранении целыми байтами требуются 12 байт, или 96 бит, включая четыре бита дополнения; коэффициент тогда равен 12 / 26 × 100 % = 46,15 %.

Таблица кодов и служебные данные декодирования в эти размеры не включены. Для короткой строки их хранение может сделать итоговый файл больше исходного. Если исходный текст хранится в UTF-8 без BOM, он занимает 50 байт (24 кириллических символа по два байта и два пробела по одному); коэффициенты относительно такого оригинала будут другими. В данном сравнении последовательно используется Windows-1251.

Представление	**Объём, бит**	**Объём, байт**	**Результат / оригинал, %**
Оригинал Windows-1251	208	26	100,00
RLE: символ + счётчик	416	52	200,00
Хаффман: полезные биты	92	11,5	44,23
Хаффман: с дополнением	96	12	46,15

Вывод: выбранный RLE не подходит для данного ФИО из-за отсутствия серий одинаковых соседних символов. Хаффман уменьшает объём полезной последовательности за счёт более коротких кодов для частых символов; выигрыш готового файла зависит от способа хранения таблицы кодов и заголовков.

Выводы

По минимальному размеру архива LZMA2 оказался лучшим для DOC, VID, PRG и SMALL; для TXT LZMA2 и PPMd дали одинаковый результат. Для PIC наименьший размер показал PPMd. Для уже сжатых изображений и видео дополнительный выигрыш невелик, а некоторые методы увеличивают размер.

Выбор метода зависит не только от размера: для SMALL преимущество LZMA2 сопровождается существенно большим временем. Значения памяти в работе являются оценками настроек, поэтому по ним нельзя делать вывод о фактически занятой памяти во время каждого запуска.

Увеличение словаря с 16 до 128 МБ не улучшило сжатие TXT; максимальный словарь оказался недоступен по памяти. Максимальный уровень сжатия почти не изменил размеры PIC и VID. Для SMALL наименьший размер дал Solid, а SFX увеличил размер обычного архива на 190 КБ. Для ФИО выбранный RLE увеличил объём, тогда как Хаффман сократил полезную последовательность до 92 бит без учёта таблицы кодов.

Архивы для проверки

По условию требуется загрузить самый маленький архив каждого каталога в облачное хранилище и предоставить доступ преподавателю. Сами архивы и ссылки на них пока не предоставлены; ниже подготовлен список для заполнения. Для TXT выбран PPMd как один из двух методов с одинаковым минимальным размером.

Каталог	Метод	Рекомендуемое имя архива	Ссылка
450389TXT	PPMd	450389TXT_PPMd.7z	[Добавить ссылку]
450389DOC	LZMA2	450389DOC_LZMA2.7z	[Добавить ссылку]
450389PIC	PPMd	450389PIC_PPMd.7z	[Добавить ссылку]
450389VID	LZMA2	450389VID_LZMA2.7z	[Добавить ссылку]
450389PRG	LZMA2	450389PRG_LZMA2.7z	[Добавить ссылку]
450389SMALL	LZMA2	450389SMALL_LZMA2.7z	[Добавить ссылку]